

Architecture offline/online pour des millions de résolutions d'un problème d'allocation concave

17 août 2026

Résumé

La réduction exacte globale conduit à une carte bidimensionnelle $\lambda^* = G(t, w)$. Cette note cherche plutôt à minimiser le coût en ligne lorsque les paramètres réels se concentrent dans des régimes étroits. Nous dérivons une formulation en (t, u, z) , des développements perturbatifs, des modèles de bande autour d'un u_0 quelconque, puis des modèles affines et quadratiques directement dans les paramètres bruts. L'examen en lecture seule de M4.3/M4.3Live révèle une simplification plus forte : les technologies ont un support discret fini et, conditionnellement à un couple de types, toute la non-linéarité dépend seulement de $C = x + y$. Le Hessien continu est alors exactement de rang un, quelles que soient les corrélations entre x et y . Un benchmark scalaire sur la distribution réelle de M4.3 conduit à une architecture hybride : formule fermée pour $\alpha = \beta$, minuscule table 1D construite paresseusement pour les couples non triviaux, et Newton robuste hors domaine.

1 Problème et critère de conception

On cherche

$$\max_{-x \leq \delta \leq y} a(x + \delta)^\alpha + b(y - \delta)^\beta, \quad 0 < \alpha, \beta < 1, \quad (1)$$

avec $a, b > 0$. En posant $C = x + y$, la solution s'écrit

$$\delta^* = C\lambda^* - x. \quad (2)$$

La réduction exacte du rapport précédent est

$$\kappa = \frac{b\beta}{a\alpha} C^{\beta-\alpha}, \quad (3)$$

$$t = \frac{\ln \kappa}{2 - \alpha - \beta}, \quad w = \frac{1 - \alpha}{2 - \alpha - \beta}, \quad (4)$$

$$\lambda^* = G(t, w). \quad (5)$$

La LUT 2D fournit un excellent baseline global, mais son coût complet inclut la normalisation, l'adressage, les accès mémoire, l'interpolation et la conversion finale. L'objectif devient donc

$$\min C_{\text{total}} = C_{\text{normalisation}} + C_{\text{adressage}} + C_{\text{memoire}} + C_{\text{interpolation}} + C_{\text{correction}}, \quad (6)$$

sous une contrainte explicite sur l'erreur de δ .

2 Ancrage dans le problème M4.3Live

Cette section résulte d'une lecture seule du dossier `jupyter/`; aucun fichier de ce dossier n'a été modifié. Le moteur de référence calcule à chaque paire un taux marginal puis un principal dans la boucle chaude `m4_3_credit_soc/m4_3/model.py` :350–381. Sa règle de principal de référence est actuellement arithmétique,

$$q_A = \frac{K_\ell - K_b}{2}, \quad (7)$$

voir le même fichier, lignes 269–291. M4.3Live prévoit des coefficients A_i et exposants γ_i par entité et leur emploi dans le taux de paire (`m4_3live_credit_soc/prompts/PROMPT_M4_3LIVE.md` :203–236).

Pour interpréter notre problème d'allocation, on pose

$$x = K_b, \quad y = K_\ell, \quad (a, \alpha) = (A_b, \gamma_b), \quad (b, \beta) = (A_\ell, \gamma_\ell). \quad (8)$$

Le transfert qui maximise la production instantanée des deux entités est alors exactement celui étudié dans ce rapport. Mais il faut distinguer le calcul et l'institution : remplacer q_A par ce transfert optimal serait une *nouvelle règle de principal*. Le prompt M4.3Live impose au contraire de conserver la cible arithmétique (lignes 186–190 et 213–230). Cette étude fournit donc un noyau candidat pour une future règle `production_optimal` ; elle ne justifie pas de modifier silencieusement M4.3Live et une telle variante ne préserverait pas la parité de trajectoire exigée par son prompt.

Dans la baseline homogène, il n'y a pas de conflit : $a = b$ et $\alpha = \beta$, donc $\lambda^* = 1/2$ et la cible arithmétique est aussi la cible de production. Avec des technologies hétérogènes, les deux cibles diffèrent généralement. En outre, le marché choisit d'abord la plus riche comme prêteuse. Si seules les transactions dans ce sens sont autorisées, le principal réalisable est

$$q^* = \max(0, \min(y, \delta^*)); \quad (9)$$

si l'institution interdit aussi de dépasser l'égalisation des capitaux, la borne supérieure devient $(y - x)/2$. Ce choix de contrainte est économique, pas numérique, et doit être fixé avant une intégration  au moteur.

3 Réduction exacte adaptée au support discret

Notons $h(C) = C\lambda^*$ le capital optimal attribué à l'entité associée à (a, α) . Alors

$$\boxed{\delta^*(x, y) = h(x + y) - x.} \quad (10)$$

En posant $p = 1 - \alpha$ et $q = 1 - \beta$, la condition du premier ordre peut s'écrire sans ambiguïté

$$p \ln h - q \ln(C - h) = \ln \frac{a\alpha}{b\beta}. \quad (11)$$

Par différentiation implicite, avec $S = p(C - h) + qh$, on obtient

$$h'(C) = \frac{qh}{S}, \quad (12)$$

$$h''(C) = \frac{pq[Ch'(C) - h(C)]}{S^2}. \quad (13)$$

Ces formules permettent de construire hors ligne une interpolation de h et de certifier ses erreurs sans différence finie.

Lorsque $\alpha = \beta = \gamma$, la fraction ne dépend plus de C :

$$\boxed{\lambda^* = \frac{a^{1/(1-\gamma)}}{a^{1/(1-\gamma)} + b^{1/(1-\gamma)}}.} \quad (14)$$

Le logarithme éventuel servant à évaluer cette constante est fait une seule fois à la création du couple de types. Le chemin en ligne se réduit ensuite à une lecture, une multiplication et une soustraction. Ceci couvre toutes les interventions ne modifiant que A ainsi que les paires dont les deux entités partagent le même γ .

4 Formulation exacte en (t, u, z)

Posons

$$z = \text{logit}(\lambda^*) = \ln \frac{\lambda^*}{1 - \lambda^*}, \quad u = 2w - 1 = \frac{\beta - \alpha}{2 - \alpha - \beta}. \quad (15)$$

Comme

$$\ln(1 + e^z) = \frac{z}{2} + \ln \left(2 \cosh \frac{z}{2} \right), \quad (16)$$

la condition d'optimalité devient exactement

$$\boxed{t = -\frac{z}{2} + uL(z), \quad L(z) = \ln \left(2 \cosh \frac{z}{2} \right).} \quad (17)$$

Pour $\alpha = \beta$, on a $u = 0$ et donc $z = -2t$ exactement.

4.1 Développement autour de $u = 0$

L'équation $z = -2t + 2uL(z)$ donne, avec $L_t = \ln(2 \cosh t)$,

$$z = -2t + 2uL_t - 2u^2 \tanh(t)L_t \quad (18)$$

$$+ u^3 [2L_t \tanh^2(t) + L_t^2 \operatorname{sech}^2(t)] + O(u^4). \quad (19)$$

Les termes proposés aux ordres un et deux sont donc corrects. Le terme cubique étend sensiblement la largeur utile de la bande autour de zéro.

4.2 Une étape de Newton et point fixe

Pour

$$F(z) = -\frac{z}{2} + uL(z) - t, \quad F'(z) = -\frac{1}{2} + \frac{u}{2} \tanh \frac{z}{2}, \quad (20)$$

une étape de Newton depuis $z_0 = -2t$ donne bien

$$z_1 = -2t + \frac{2u \ln(2 \cosh t)}{1 + u \tanh t}. \quad (21)$$

L'itération de point fixe

$$z_{k+1} = -2t + 2uL(z_k) \quad (22)$$

a pour dérivée $u \tanh(z/2)$. Or $|u| < 1$ lorsque $0 < \alpha, \beta < 1$. Elle est donc contractante sur $\mathbb{R}$, avec facteur de contraction au plus $|u|$. Cette garantie est globale, mais la convergence n'est réellement rapide que lorsque $|u|$ est modéré.

5 Bande locale autour d'un u_0 quelconque

Écrivons

$$z(t, u) \simeq z_0(t) + (u - u_0)z_u(t, u_0) + \frac{1}{2}(u - u_0)^2 z_{uu}(t, u_0). \quad (23)$$

Avec

$$T = \tanh(z/2), \quad Q = 1 - T^2, \quad z_{uu} = 1 - uT, \quad (24)$$

la différentiation implicite de (17) donne

$$z_u = \frac{2L(z)}{D}, \quad (25)$$

$$z_{uu} = \frac{2Tz_u + \frac{1}{2}uQz_u^2}{D}. \quad (26)$$

Trois LUT 1D en t suffisent donc pour l'ordre deux. Pour une demi-largeur $h = |u - u_0|$, le reste de Taylor vérifie

$$|R_2| \leq \frac{h^3}{6} \sup_{|u - u_0| \leq h} |z_{uuu}(t, u)|. \quad (27)$$

Comme $\sigma'(z) \leq 1/4$ pour la sigmoïde,

$$|\hat{\lambda} - \lambda^*| \leq \frac{1}{4} |\hat{z} - z^*|, \quad |\hat{\delta} - \delta^*| \leq \frac{C}{4} |\hat{z} - z^*|. \quad (28)$$

Les dérivées d'ordre supérieur peuvent être tabulées ou majorées hors ligne sur chaque bande, ce qui fournit un certificat de validité en ligne très peu coûteux.

6 Corrélations, interactions et métrique locale

6.1 Conditionner avant de réduire

Dans M4.3Live, (A_i, γ_i) prend un petit nombre de valeurs exactes. Ces valeurs sont des catégories technologiques, non de petites perturbations gaussiennes. Une PCA sur $(a, b, \alpha, \beta, x, y)$ attribuerait donc une distance artificielle entre catégories et mélangerait des régimes que le code peut router exactement. La bonne première




FIGURE 1 – Erreur maximale des approximations centrées en $u_0 = 0$.




FIGURE 2 – Erreur maximale d'une bande centrée en $u_0 = 0,45$.

opération est de conditionner sur le couple ordonné de types technologiques, puis d'analyser la distribution continue de (x, y) dans chaque cellule.

À couple fixé, soit $e = (1, 1)^T$. L'équation (10) donne exactement

$$g = \nabla_{x,y} \delta^* = \begin{pmatrix} h' - 1 \\ h' \end{pmatrix}, \quad H = \nabla_{x,y}^2 \delta^* = h'' e e^T = h'' \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}. \quad (29)$$

Le terme croisé $2h''\Delta x\Delta y$ est réel et ne doit pas être supprimé. Mais le Hessien est de rang un : il ne représente qu'une courbure dans la direction $\Delta C = \Delta x + \Delta y$. La direction transverse intervient exactement et seulement par le terme linéaire $-x$.

Autour de C_0 , un modèle local structurel est donc

$$\hat{\delta}_2 = h(C_0) + h'(C_0)\Delta C + \frac{1}{2}h''(C_0)\Delta C^2 - x, \quad (30)$$

et non un polynôme quadratique général à six variables. Pour $|\Delta C| \leq R_C$,

$$|\delta^* - \hat{\delta}_1| \leq \frac{1}{2} \sup |h''| R_C^2, \quad (31)$$

$$|\delta^* - \hat{\delta}_2| \leq \frac{1}{6} \sup |h'''| R_C^3. \quad (32)$$

Les corrélations entre x et y n'affaiblissent pas ces bornes : elles changent la distribution de ΔC , pas la forme fonctionnelle.

Sur le couple illustratif $(a, \alpha) = (1, 0.5)$, $(b, \beta) = (1.25, 0.6)$ au centre réel $C_0 = 1589.6$, l'erreur maximale affine vaut $1.15 \cdot 10^{-3}$ pour une demi-largeur de 1 % et $1.19 \cdot 10^{-1}$ pour 10 %. Le quadratique de rang un ramène ces erreurs à $4.52 \cdot 10^{-6}$ et $4.76 \cdot 10^{-3}$. Les pentes en R_C^2 et R_C^3 confirment les restes de Taylor, mais montrent aussi qu'un atlas affine doit avoir des cellules assez étroites.




FIGURE 3 – Erreur locale en fonction du rayon dans l'unique direction non linéaire C . Les deux orientations du couple donnent ici les mêmes amplitudes d'erreur.

6.2 Covariance et Hessien sont deux objets distincts

Soit

$$\Sigma = \text{Cov}[(x, y)^T \mid \text{couple de types}]. \quad (33)$$

Σ décrit les directions parcourues, tandis que H décrit les interactions de la solution. Au premier ordre,

$$\text{Var}(\delta^*) \simeq g^T \Sigma g. \quad (34)$$

Une matrice libre M dans $\delta^T M T_1$ n'ajoute aucun pouvoir expressif pour cette sortie scalaire, puisque $M T_1$ est un vecteur. Elle ne devient utile que si elle est partagée entre plusieurs sorties, impose un rang faible, stabilise les coordonnées ou réduit le nombre de coefficients variant avec le régime.

Factorisons $\Sigma = LL^T$ et posons $(\Delta x, \Delta y)^T = L\xi$. Dans les coordonnées blanches,

$$K = L^T H L = h''(L^T e)(L^T e)^T. \quad (35)$$

Ainsi K possède exactement une seule valeur propre non nulle,

$$\mu = h''e^T \Sigma e = h'' \text{Var}(C), \quad (36)$$

quel que soit le caractère oblique ou corrélé de la distribution. La correction quadratique de rang minimal vaut donc $r = 1$ exactement. Ce résultat est plus fort qu'une décroissance empirique de spectre.

Pour une analyse active au premier ordre, la matrice pertinente reste

$$A = \Sigma^{1/2} \mathbb{E}[gg^T \mid \text{type}] \Sigma^{1/2}, \quad (37)$$

à comparer à la PCA de Σ [2, 1]. Cependant, l'implémentation n'a pas besoin d'en calculer les vecteurs propres à chaque requête : la transformation oblique fixe $(x, y) \mapsto (C, x) = (x + y, x)$ sépare déjà exactement la partie non linéaire de la partie linéaire. La covariance sert à choisir les bornes et la densité de la table, non à découvrir une direction que l'algèbre donne gratuitement.

Si les distributions évoluent le long du temps ou d'un régime z , on estime $\Sigma(z)$ par fenêtres ou par cellules technologiques. Il n'est rentable de stocker plusieurs métriques que si cela modifie effectivement les bornes de table. Une matrice 6×6 interpolée en ligne serait ici un surcoût sans gain : une matrice de fréquences des couples de types et quelques quantiles de C par cellule suffisent.

Plus généralement, une écriture $X = \phi(z) + B(z)\delta$ n'impose aucune orthogonalité aux colonnes de B . Une base oblique, blanchissante ou choisie pour réduire les FMA est admissible. Pour une sortie scalaire au premier ordre, $\delta^T M(z) T_1(z) = \delta^T \tilde{T}_1(z)$: une matrice M libre ne réduit donc pas l'erreur. Elle apporte quelque chose seulement si elle est partagée entre plusieurs sorties, contrainte à bas rang, presque constante par morceaux, ou si elle permet de remplacer plusieurs coefficients dépendant de z par quelques projections fixes. Le choix pratique consiste à tester $k = 0, 1, 2, \dots$ directions et à conserver une direction supplémentaire uniquement si la réduction d'erreur de sortie rembourse son adressage et ses produits scalaires.

Dans le problème présent, la base oblique $(C, x) = (x + y, x)$ atteint directement ce rang minimal : $k = 1$ pour la correction non linéaire, plus le terme $-x$ exact. Si la covariance varie avec le régime, on peut ajuster la densité des points par tranches temporelles ou technologiques sans jamais interpoler $B(z)$, $M(z)$ ou $H(z)$ en ligne. Pour un problème futur où cette structure disparaîtrait, on comparerait une base globale, quelques bases constantes par morceaux, puis seulement une factorisation variable basse-rang ; l'ordre est dicté par le coût online.

6.3 Ce que montrait malgré tout le test générique 6D

Avant l'inspection de M4.3, un test synthétique continu à six paramètres avait montré que la première direction active expliquait 99,69 % du spectre, alors que la PCA était presque uniforme. Cela confirme qu'une faible dimension géométrique et une faible dimension de sortie ne sont pas synonymes. La structure exacte (29) rend toutefois ce surrogat 6D inutile pour le moteur réel : il est préférable de ne pas approximer les catégories.

7 Domaine réel parcouru et cache discret

Le fichier historique de la baseline arithmétique contient 9366177 événements de prêt. Un échantillonnage déterministe d'un événement sur 997 donne 9395 paires. Pour la règle arithmétique, les colonnes enregistrées permettent de reconstruire exactement les capitaux avant transfert :

$$x = K_{b,\text{after}} - q_A, \quad y = K_{b,\text{after}} + q_A, \quad C = 2K_{b,\text{after}}. \quad (38)$$

On mesure $\text{corr}(x, y) = 0,412$ et $\text{corr}(\ln x, \ln y) = 0,299$: les influences ne sont donc pas orthogonales. La corrélation entre C et le transfert courant vaut $-0,567$. Les quantiles 0,1 % et 99,9 % de C valent respectivement 192,0 et 2213,6, avec une médiane 1589,6.

7.1 Indexation par type, pas par flottants

Chaque technologie distincte $\theta_s = (A_s, \gamma_s)$ reçoit un petit identifiant entier au moment où elle apparaît. Une matrice dense de pointeurs `kernel[s_receiver][s_donor]` route alors un couple en $O(1)$, sans recherche de centre et sans table de hachage sur des flottants. Si S est le nombre de technologies réalisées, il existe au plus S^2 noyaux ordonnés, mais beaucoup utilisent (14) et ne possèdent aucune LUT.




FIGURE 4 – Test générique : spectre actif et spectre PCA. Dans M4.3 conditionné par type, la partie non linéaire est analytiquement de rang un.




FIGURE 5 – Corrélation des capitaux et domaine de C réellement parcouru. Lecture seule d'un run M4.3 de référence.

Pour $\alpha \neq \beta$, une LUT 1D stocke directement $h(C)$, et non z ou λ . Afin d'éviter $\ln C$, on écrit la représentation flottante

$$C = m, 2^e, \quad m \in [1/2, 1[, \quad (39)$$

obtenue par **frexp**. L'exposant choisit une petite ligne et la mantisse adresse une grille uniforme. Deux versions sont utiles : interpolation linéaire très rapide, ou cubique de Hermite dont les coefficients sont précompilés avec (12). L'évaluation cubique est un schéma de Horner, sans logarithme, exponentielle ni division.

Les lignes d'exposant couvrant le domaine chaud sont construites au premier emploi. Un C extérieur est envoyé vers Newton, puis la ligne manquante peut être ajoutée. La couverture globale ne dépend donc pas d'une extrapolation.

7.2 Pseudo-algorithme paresseux

```
on_new_technology(A, gamma):
    id <- intern_exact_pair(A, gamma)
    agrandir kernel[id][*] et kernel[*][id]
    pour chaque type j déjà réalisé:
        si gamma_id == gamma_j:
            stocker lambda constante exacte
        sinon:
            état <- COLD (Newton exact)

solve(receiver, donor, x, y):
    k <- kernel[type(receiver)][type(donor)]
    C <- x + y
    si k.constant_lambda: target <- k.lambda * C
    sinon si k.table_covers(C): target <- k.table_h(C)
    sinon:
        target <- newton_exact(C, k.precomputed_constants)
        k.observe(C) # aucun RNG, aucune dynamique modifiée
        si compteur >= seuil: compiler/étendre la table
    delta <- target - x
    retourner clamp(delta, contraintes_institutionnelles)
```

La compilation peut être exécutée au début du pas où une intervention est appliquée. Elle ne consomme aucun tirage aléatoire et ne change donc pas la trajectoire, seulement la durée murale de ce pas. Une machine d'états COLD/BUILDING/HOT et un remplacement atomique du pointeur suffisent si la construction est déportée sur un thread. Connaissant à l'avance le support d'une campagne, on peut naturellement préchauffer la matrice avant le chronométrage.

8 Résultats de performance

8.1 Boucle scalaire conforme au moteur M4.3Live

Le benchmark principal utilise la distribution de (x, y) ci-dessus et un support technologique illustratif $(A, \gamma) \in \{1, 1.25\} \times \{0.5, 0.6\}$, soit 16 couples ordonnés. Ce support sert uniquement à solliciter les chemins hétérogènes ; les valeurs futures de l'expérience M4.3Live devront remplacer ce plan de test. La moitié des couples ont des exposants égaux. Les mesures portent sur 300 000 appels scalaires Python, cinq répétitions, meilleur temps :

Méthode	Mreq/s	erreur max $ \Delta\delta $	mémoire
M4.3 arithmétique homogène	9,47	exacte	0
Cache $\lambda, \alpha = \beta$	7,28	exacte	quelques octets
Newton 5, constantes en cache	0,467	référence	0
Une étape Newton depuis $u = 0$	1,53	$2,50 \cdot 10^{-1}$	0
Point fixe, deux tours	1,27	$4,95 \cdot 10^{-1}$	0
LUT frexp linéaire	1,80	$4,42 \cdot 10^{-4}$	40,3 Kio
LUT Hermite, formule directe	1,09	$1,36 \cdot 10^{-9}$	80,6 Kio
LUT cubique précompilée	1,63	$1,36 \cdot 10^{-9}$	160 Kio

La LUT cubique précompilée est 3,49 fois plus rapide que Newton sur le mix complet, à une erreur inférieure à $1,4 \cdot 10^{-9}$ en unités de capital. La LUT linéaire est préférable si une tolérance $5 \cdot 10^{-4}$ suffit. Une étape de Newton autour de $u = 0$ est sans coût de construction et peut convenir à une tolérance absolue grossière, mais son erreur en δ est amplifiée par les valeurs de C de l'ordre de 10^3 ; une petite erreur en λ ne doit donc pas être jugée seule.

La construction robuste des huit tables non triviales prend 43,4 ms, soit environ 5,4 ms par entrée. En séparant le coût des couples $\alpha = \beta$, le seuil d'amortissement face à Newton exact est de l'ordre de 1800 utilisations par couple non trivial. Face à l'unique étape de Newton, le seuil est beaucoup plus élevé et ne se justifie que si la tolérance exige la précision de la LUT. Ces seuils doivent être recalibrés sur la machine de production.




FIGURE 6 – Débit scalaire et compromis coût–précision sur la distribution M4.3. Les accès hors de la plage chaude utilisent le fallback exact.

8.2 Benchmark vectorisé générique

Les mesures suivantes utilisent NumPy, un processus, des tableaux d'un million d'observations et incluent la conversion finale vers λ . Elles comparent les noyaux en (t, u) sur $t \in [-8, 8]$ et $u \in [-0,35, 0,35]$.

Méthode	s/1M	Mreq/s	Table
Newton exact, 7 tours	0,984	1,02	0
LUT 2D	0,238	4,21	4,02 Mio
LUT 2D + Newton	0,350	2,86	4,02 Mio
Série en u , ordre 1	0,111	8,99	0
Série en u , ordre 2	0,155	6,46	0
Série en u , ordre 3	0,227	4,41	0
Newton depuis $u = 0$	0,168	5,95	0
Newton depuis $u = 0$, LUT 1D	0,149	6,70	32 Kio
Point fixe, 2 tours	0,183	5,47	0
Bande ordre 2	0,168	5,95	48 Kio
Bande ordre 2 + Newton	0,280	3,57	48 Kio

Pour les six paramètres bruts, sur un domaine local standardisé de rayon 0,2, on obtient :

Méthode	s/1M	Mreq/s	Modèle
Newton global	0,964	1,04	—
LUT 2D globale	0,225	4,45	4,02 Mio
Affine brut	0,0064	156,96	56 octets
Quadratique rang 1	0,022	44,67	112 octets
Quadratique rang 2	0,052	19,43	168 octets
Quadratique complet	0,181	5,54	344 octets
(t, u) linéarisés + bande 2	0,152	6,59	48 Kio

L'erreur maximale de l'anne brut vaut environ $8,0 \cdot 10^{-5}$ au rayon 0,05, $3,2 \cdot 10^{-4}$ au rayon 0,1 et $1,3 \cdot 10^{-3}$ au rayon 0,2. Pour le quadratique complet, elle vaut respectivement $6,1 \cdot 10^{-7}$, $4,9 \cdot 10^{-6}$ et $3,9 \cdot 10^{-5}$, conformément aux lois en R^2 et R^3 attendues.

Ces résultats sont spécifiques à la machine et aux distributions de test. Le modèle Roofline rappelle qu'une LUT peut devenir limitée par la bande passante et la hiérarchie mémoire plutôt que par les opérations arithmétiques [5]. Toute décision finale doit donc être jouée sur l'architecture cible.

9 Paramètres répétés, lots et coût d'adressage

Lorsque (a, b, α, β) sont constants sur un scénario,

$$u = \text{constante}, \quad t = A + B \ln C, \quad (40)$$

où A , B et u sont pré-calculés. Une seule LUT 1D de $z(t, u)$ suffit. Sur le test $C \in [e^{-0,3}, e^{0,3}]$, cette méthode atteint 10,86 Mreq/s avec une erreur maximale $5,4 \cdot 10^{-8}$. Lorsque $\alpha = \beta$, $B = 0$ et la formule directe $\delta = C\lambda^* - x$ atteint 156,5 Mreq/s.

Le routage d'un atlas peut annuler une partie du gain. Dans un atlas synthétique de huit régimes :

Adressage	Mreq/s
Identifiant de régime déjà connu	11,89
Identifiant connu + test de validité	6,15
Recherche exhaustive parmi 8 centres	1,60

La recherche exhaustive est presque aussi coûteuse qu'une résolution exacte. Les observations doivent donc être triées par scénario, ou le régime précédent doit être conservé pour une série temporelle. Une nouvelle recherche n'est déclenchée qu'à la sortie du domaine de validité.

10 Construction automatique offline

Une procédure pratique sur un échantillon représentatif est :

1. identifier d'abord les contraintes exactes et les supports discrets ; dans M4.3Live, attribuer des identifiants aux technologies et partitionner les observations par couple ordonné ;
2. dans chaque cellule, estimer la fréquence, les quantiles de C , la covariance Σ de (x, y) et les erreurs du fallback rapide ;
3. vérifier séparément la sensibilité par g , les interactions par H et la matrice blanchie $K = L^T H L$; ne pas interpréter Σ comme un Hessien ni une catégorie comme une variable continue ;
4. construire d'abord la formule fermée si les exposants sont égaux, puis les LUT 1D de $h(C)$ seulement pour les cellules assez fréquentes ;
5. choisir pour chaque cellule le nombre de points minimal satisfaisant l'erreur max ou le quantile d'erreur imposé sur validation indépendante ;
6. mesurer le coût de construction et ne promouvoir la cellule en HOT qu'après son seuil d'amortissement ;
7. pour un autre problème ne possédant pas la réduction (10), calculer des solutions exactes et des gradients sur un ensemble d'apprentissage, puis examiner séparément PCA et matrice active (37) ;
8. partitionner les observations restantes en régimes denses ;
9. ajuster dans chaque régime un modèle affine, puis quadratique de rang croissant jusqu'à atteindre la tolérance ;
10. si les données forment une bande dans (t, u) , ajuster une ligne centrale $u = \phi(t)$ ou une courbe paramétrée par longueur d'arc s ;
11. projeter chaque point sur cette courbe et définir une coordonnée transverse r , puis ajuster

$$z(s, r) \simeq Z_0(s) + rZ_1(s) + r^2Z_2(s); \quad (41)$$

12. valider sur un jeu indépendant et construire une enveloppe d'erreur en fonction de la distance au centre ou au tube ;
13. mesurer le coût complet, adressage compris, et fusionner les régimes dont le gain n'est pas supérieur au coût de routage.

Les modèles locaux et leurs domaines de confiance sont proches des idées de modèles de région de confiance et de surrogates locaux [3, 4]. Une représentation active doit toujours être validée sur la sortie, pas seulement sur la géométrie des entrées.

11 Architecture recommandée

La LUT 2D devient le baseline global, non la solution finale.

Hot path.

- identifiants technologiques stockés avec les entités, adressage direct dans une matrice $S \times S$;
- formule exacte (14) dès que $\gamma_b = \gamma_\ell$; en particulier, aucune LUT pour une campagne ne modifiant que A ;
- sinon LUT 1D de $h(C)$ indexée par **frexp**, linéaire ou cubique selon la tolérance ;
- soustraction exacte de x et clamp imposé par l'institution.

Warm path. Noyau sans table (une étape de Newton ou deux points fixes) pendant la phase d'observation d'un nouveau couple, ou petite LUT en cours d'extension. Les constantes $(t_0, t_{\log C}, u)$ sont déjà stockées dans l'entrée de cache.

Cold path. Newton robuste pour une première occurrence, un exposant de C non couvert, ou un audit aléatoire. Une LUT 2D globale n'est plus nécessaire dans M4.3Live, car le support discret transforme chaque cellule en problème 1D ; elle reste le baseline universel si les technologies redeviennent continues.

Régime observé	Tolérance indicative	Choix initial
$\alpha = \beta$	toute	fraction constante exacte
Nouveau couple, $n < 1800$	forte	Newton exact en cache froid
Couple fréquent, run observé	$5 \cdot 10^{-4}$	LUT frexp linéaire
Couple fréquent, run observé	$2 \cdot 10^{-9}$	cubique précompilée
C hors lignes présentes	précision forte	Newton + extension paresseuse
Technologies continues futures	précision forte	LUT 2D + Newton

Ces frontières sont issues du benchmark synthétique et doivent être recalculées sur les données réelles. La politique finale doit minimiser un coût espéré

$$\mathbb{E}[C] = p_{\text{hot}} C_{\text{hot}} + p_{\text{warm}} C_{\text{warm}} + p_{\text{cold}} C_{\text{cold}}, \quad (42)$$

avec une contrainte sur l'erreur maximale ou sur un quantile métier.

Conclusion

La propriété décisive du cas réel est la combinaison de deux faits : support technologique discret et conservation $C = x + y$. Une fois le couple de types connu, $\delta^* = h(C) - x$ et toute la courbure est exactement de rang un, indépendamment des corrélations des capitaux. Il n'y a donc ni LUT 2D à lire ni modèle quadratique 6D à évaluer dans le chemin chaud.

L'architecture au coût online minimal est une matrice de petits noyaux créée à la volée. Les paires d'exposants égaux utilisent une constante exacte ; les autres reçoivent une table 1D seulement après environ un millier d'usages, puis Newton reste le fallback hors plage. La covariance réelle sert à placer et à étendre les tables, tandis que le Hessien analytique fixe leur rang. Enfin, adopter ce calcul comme règle de principal serait une modification institutionnelle de M4.3Live : il doit rester un mode expérimental explicite, comparé à la règle arithmétique, et non une optimisation interne invisible.

Références

- [1] P. Constantine, *Active Subspaces: Emerging Ideas for Dimension Reduction in Parameter Studies*, SIAM, 2015.
- [2] P. Constantine, E. Dow et Q. Wang, *Active Subspace Methods in Theory and Practice*, SIAM Journal on Scientific Computing, 2014.
- [3] A. Conn, K. Scheinberg et L. Vicente, *Introduction to Derivative-Free Optimization*, SIAM, 2009.
- [4] A. Forrester, A. Sóbester et A. Keane, *Engineering Design via Surrogate Modelling*, Wiley, 2008.
- [5] S. Williams, A. Waterman et D. Patterson, *Roofline: An Insightful Visual Performance Model*, Berkeley, 2008.
- [6] L. N. Trefethen, *Approximation Theory and Approximation Practice*, SIAM.