

Familles de lois pour la distribution en taille et en revenu de la population d'entités — `modele-27-04-WIP`

Note technique — Claude Code, à la demande d'Anatole Joseph-Stouls

2 juillet 2026

Résumé

On cherche la famille de lois (ou combinaison de lois) qui décrit le mieux, à un pas de temps stationnaire, la distribution en taille des entités (`actif_total` / `passif_total`) et la distribution de leurs revenus (`revenu_total` = extraction $\alpha\sqrt{P}$ + intérêts reçus) dans les simulations du modèle `modele-27-04-WIP`. L'hypothèse de départ — un mélange de deux lois log-normales, jugé insatisfaisant — est testée contre une échelle de familles à 1 à 5 paramètres (exponentielle, Fisk, Singh-Maddala, GB2, mélanges). Le mélange à 2 log-normales gagne systématiquement au sens de l'AIC/BIC, sur 163 simulations stationnaires regroupées par régime physique. Mais l'origine du mélange n'est pas ce que l'hypothèse de départ supposait : ses deux composantes correspondent à deux *cohortes d'âge* (entités fondatrices créées à $t = 0$ contre entités entrantes créées en continu), pas à deux types économiques distincts. Un test de dérive avec la durée simulée montre en outre que la queue de la distribution s'alourdit avec le temps : ce n'est pas une loi d'échelle stable, mais un artefact transitoire lié au protocole d'amorçage.

Table des matières

1	Contexte et question posée	1
2	Méthode	1
2.1	Sélection des simulations	1
2.2	Principe : pas de pooling	2
2.3	Échelle de familles testées	2
3	Résultat 1 — l'origine du « mélange » est démographique, pas économique	2
4	Résultat 2 — hiérarchie des familles par nombre de paramètres	3
4.1	Paramètres typiques du mélange gagnant	4
5	Résultat 3 — la queue n'est pas une loi de puissance stable	5
6	Recommandations pratiques	6
7	Limites et pistes	6

1 Contexte et question posée

Le modèle `modele-27-04-WIP` (source dans `modele-27-04-WIP/src`) simule une population d'entités économiques créées en continu, empruntant et prêtant un actif unique (le joule), avec faillites possibles. La question posée : quelle famille de lois décrit le mieux, pour un nombre de

paramètres donné (1 à 5), la distribution transversale (à un instant donné, sur toutes les entités vivantes)

- de la **taille** des entités (`actif_total` ou `passif_total`);
- de leur **revenu** (`revenu_total`, extraction $\Pi = \alpha\sqrt{P}$ plus intérêts reçus) ?

L’ajustement actuellement utilisé dans `analysis.py` (`_fit_lognormal_mixture`) est un mélange de deux lois log-normales, jugé peu satisfaisant par l’auteur, qui soupçonnait deux populations qui se chevauchent sans être certain de la nature de cette hétérogénéité.

2 Méthode

2.1 Sélection des simulations

Sur les 805 simulations disponibles issues de ce modèle (13 lancées directement, 792 issues de l’étude de sensibilité `etude_sensibilite_27_04_wip`, même code source), **163 seulement sont stationnaires** au sens déjà calculé par le harnais de sensibilité (`run_simulation.py:detect_regime_diagnost` — queue bornée (`bounded_tail`) et flux de faillites en équilibre avec le flux de création (`flow_balanced`). Ce filtrage est nécessaire : le processus brownien géométrique sur α documenté dans `simulation.py` porte un *drift positif* explicitement signalé comme problème dans le code source, et la majorité des simulations ne convergent jamais vers un régime stable.

2.2 Principe : pas de pooling

Les valeurs ne sont **jamais regroupées** entre simulations ni entre pas de temps avant ajustement — regrouper des runs à paramètres différents, ou des pas de temps différents d’une même trajectoire encore transitoire, fabrique artificiellement de la multimodalité qui n’existe dans aucune simulation individuelle. La méthode retenue est donc : un ajustement par paramètres maximum de vraisemblance (MLE) sur **un seul instantané stationnaire par simulation**, puis agrégation des verdicts (famille gagnante, valeurs de paramètres) sur l’ensemble des simulations d’un même groupe.

Les simulations sont regroupées par les leviers physiques du modèle : `n_candidats_pool` (k , taille du pool de négociation crédit — $k \leq 2$: régime stable, $k \geq 3$: régime critique auto-organisé selon `config.py`), homogénéité de α ($\alpha_{\min} = \alpha_{\max}$?) et σ_α (volatilité du brownien sur α). Un regroupement par apprentissage non supervisé sur la forme des distributions aurait été circulaire (on aurait regroupé les runs sur l’objet même qu’on cherche à caractériser).

L’instant de mesure retenu par simulation est le pas recommandé par le harnais (`t_measure / tail_start / t_regime` selon le schéma disponible), ou à défaut le dernier instantané disponible.

2.3 Échelle de familles testées

Treize familles ont été ajustées par MLE sur les valeurs strictement positives, comparées par AIC et BIC :

Paramètres	Familles
1	Exponentielle, Pareto ($x_{\min}$ fixé au minimum observé)
2	Log-normale, Gamma, Weibull, Fisk (log-logistique)
3	Log-normale à 3 paramètres, Gamma généralisée, Singh-Maddala (Burr XII), Dagum (Burr III)
4	GB2 (Generalized Beta of the Second Kind, McDonald 1984) — ajustée par MLE numérique (implémentation propre, pas disponible dans <code>scipy</code>)
5	Mélange de 2 log-normales (méthode existante du dépôt), mélange log-normale + queue de Pareto (méthode existante du dépôt)

Les familles à 2–4 paramètres forment une hiérarchie *emboîtée* : Fisk $\subset$ Singh-Maddala $\subset$ GB2 (Fisk = GB2 avec $p = q = 1$, Singh-Maddala = GB2 avec $q = 1$). C’est volontaire : cela permet de savoir si ajouter un paramètre à une même famille structurelle suffit, ou s’il faut changer de structure (mélange).

Le code complet est dans `scripts/` (`families.py` pour l’échelle de familles, `lib.py` pour le chargement des données, `batch_run.py` pour l’exécution en parallèle, `aggregate.py` pour l’agrégation, `tail_test.py` pour le test de queue). Les résultats bruts par simulation sont dans `results/` (JSON).

3 Résultat 1 — l’origine du « mélange » est démographique, pas économique

L’hypothèse de départ était que le mélange reflète deux populations d’entités économiquement distinctes. Les données ne le confirment pas : elles pointent vers une origine **démographique**.

Sur `entity_final_state.csv` (état final de toutes les entités, avec `creation_step`), on calcule l’âge de chaque entité vivante en fin de simulation. La corrélation entre âge et $\log(\text{actif_total})$ est de **0,88 à 0,95** selon les groupes — y compris dans les groupes à α *hétérogène* ($\sigma_\alpha = 0,02$), où l’âge domine toujours le type de productivité comme facteur explicatif de la taille.

Plus frappant : la distribution des âges elle-même est nettement bimodale, avec un **trou démographique** quasi total entre les deux modes (figure 1) : une entité créée après $t = 0$ soit fait faillite tôt (dans les premiers 10–15 % de la durée simulée), soit devient quasiment immortelle. Il n’existe presque aucune entité d’âge intermédiaire. Sur le groupe dominant ($k = 4$, α homogène, $\sigma = 0$, $n = 54$ simulations), la fraction de « fondateurs » (âge $> 85\%$ de la durée simulée) varie de 10 à 35 % selon la simulation, contre 0 à 11 % d’entités d’âge intermédiaire.




FIGURE 1 – Structure démographique de la population vivante en fin de simulation (run représentatif, $k = 4$, α homogène, $\sigma = 0$, $T = 999$). À gauche : taille en fonction de l’âge, échelle log en ordonnée — corrélation 0,88. À droite : distribution des âges, avec le trou démographique entre les entrants récents et les fondateurs survivants.

Ce schéma s’explique par le protocole d’amorçage du modèle : 100 entités sont créées *simultanément* à $t = 0$ (`n_entites_initiales`), puis les entités suivantes arrivent en continu (processus de type Poisson, taux `lambda_creation`). Les 100 fondateurs, qui n’ont jamais été renouvelés, compoundent leur croissance sur toute la durée de la simulation sans jamais mourir une fois établis — ils forment la queue lourde. Les entrants continus, eux, meurent presque tous rapidement ; les rares survivants forment le corps étroit de la distribution.

Conclusion : l'intuition de deux populations qui se chevauchent est correcte, mais ce sont deux *cohortes d'âge* (fondateurs contre entrants), pas deux classes économiques différentes. C'est un artefact du protocole d'initialisation de la simulation, pas une loi structurelle de l'économie modélisée.

4 Résultat 2 — hiérarchie des familles par nombre de paramètres

Le tableau 1 donne la famille gagnante (au sens de l'AIC) pour chaque nombre de paramètres, sur les quatre groupes comportant au moins 15 simulations stationnaires (tous à α homogène, $\sigma = 0$) ; le résultat est identique pour `actif_total` et `revenu_total`, et remarquablement stable d'un groupe à l'autre.

k	n	1p	2p	3p	4p	5p
3	22	Exponentielle	Fisk	Singh-Maddala	GB2	Mélange log-log
4	54	Exponentielle	Fisk	Singh-Maddala	GB2	Mélange log-log
5	26	Exponentielle	Fisk / log-nor.	Singh-Maddala	GB2	Mélange log-log
6	15	Exponentielle	Fisk / log-nor.	Singh-Maddala	GB2	Mélange log-log

TABLE 1 – Famille gagnante par nombre de paramètres, `actif_total` et `revenu_total` (résultat identique), pour chaque valeur de $k = \text{n_candidats_pool}$ disposant d'au moins 15 simulations stationnaires. « Mélange log-log » = mélange de 2 log-normales.

Mise en garde sur le palier à 4 paramètres. Le GB2 gagne l'AIC à 4 paramètres, mais son optimum se trouve en pratique sur une forme *dégénérée* : le paramètre de forme a vient buter sur la borne numérique imposée ($a = 50$), ce qui produit une fonction de survie qui s'effondre presque verticalement (figure 2, courbe verte pointillée) — un ajustement en quasi-fonction-marche, pas une forme plausible. Autrement dit : *aucune famille lisse et unimodale ne parvient à représenter un corps étroit accolé à une queue lourde*. C'est précisément le signal qui justifie le saut vers un mélange explicite à 5 paramètres, cohérent avec la structure à deux cohortes du résultat 3. Le gain du mélange sur le GB2 est net (médiane $\Delta\text{BIC} \approx -100$ à -120 selon la variable, sur le groupe $k = 4$), donc ce n'est pas un artefact de sur-paramétrage : c'est une amélioration structurelle réelle.




FIGURE 2 – Fonction de survie empirique (points noirs, échelle log-log) contre les quatre meilleures familles à 2, 3, 4 et 5 paramètres, pour `actif_total` (gauche) et `revenu_total` (droite), sur une simulation représentative du groupe $k = 4$, α homogène, $\sigma = 0$.

4.1 Paramètres typiques du mélange gagnant

Sur le groupe dominant ($k = 4$, α homogène, $\sigma = 0$, $n = 54$), médiane des paramètres ajustés (convention `scipy.stats.lognorm` : $\text{LN}(\mu, \sigma)$, échelle = e^μ) :

Variable	λ	Composante 1 (jeunes)	Composante 2 (fondateurs)
<code>actif_total</code>	0,51	médiane 313 ($\sigma_1 = 0,060$)	médiane 515 ($\sigma_2 = 0,440$)
<code>revenu_total</code>	0,51	médiane 17,6 ($\sigma_1 = 0,031$)	médiane 23,7 ($\sigma_2 = 0,256$)

La composante 1 (entrants) est très resserrée ($\sigma_1 \approx 0,03\text{--}0,06$, coefficient de variation $\approx$ quelques %) : elle correspond à une taille « typique » que les jeunes entités atteignent rapidement puis autour de laquelle elles stagnent avant de faire faillite ou d’être remplacées. La composante 2 (fondateurs) est beaucoup plus dispersée ($\sigma_2 \approx 0,26\text{--}0,44$), cohérent avec une croissance composée sur des durées très variables.

5 Résultat 3 — la queue n’est pas une loi de puissance stable

La fonction de survie empirique décroche visiblement au-dessus de la prédiction du mélange dans la queue extrême (figure 2) : la composante log-normale de queue décroît trop vite pour les plus grandes valeurs observées. C’est probablement ce que l’auteur perçoit comme un « mauvais ajustement » malgré un bon score AIC/BIC global (dominé par le corps de la distribution, où l’accord est bon : écart de Kolmogorov-Smirnov médian de 0,04, sous le seuil critique à 5 % pour $n \approx 300$).

Un test de type Clauset–Shalizi–Newman (recherche du seuil $x_{\min}$ par minimisation de la distance de Kolmogorov-Smirnov, puis test du rapport de vraisemblance loi de puissance contre log-normale sur la queue au-delà de $x_{\min}$) favorise la loi de puissance sur la log-normale dans la queue, de façon quasi systématique (rapport de vraisemblance positif dans 95 à 100 % des simulations selon le groupe).

Mais il ne s’agit probablement pas d’une vraie loi d’échelle. Le mécanisme identifié en section 3 — une cohorte fixe de fondateurs qui compound indéfiniment sans jamais être renouvelée ni tuée — est un mécanisme de *diffusion log-normale*, pas le mécanisme de renouvellement/rescaling (processus de Kesten) qui produit usuellement les vraies lois de puissance en

économie. Un test décisif : une loi d'échelle véritable a un exposant de queue stable quelle que soit la durée simulée T ; un artefact transitoire dérive avec T .




FIGURE 3 – Poids de la cohorte de fondateurs (gauche) et exposant de queue estimé par la méthode Clauset–Shalizi–Newman (droite) en fonction de la durée simulée T . Points gris : simulations individuelles ; losanges rouges : médiane par palier de T .

Les deux quantités **dérivent nettement avec T** (figure 3) : la fraction de fondateurs passe de 34 % à $T \approx 1000$ à 23 % à $T \approx 1500$ puis 13 % à $T \approx 3000$; l'exposant de queue passe de 5,4 à 5,0 puis 3,1 sur les mêmes paliers (plus l'exposant est petit, plus la queue est lourde). Une vraie loi d'échelle serait stable ; ici, la queue s'alourdit mécaniquement à mesure que les fondateurs ont plus de temps pour composer leur croissance.

Conclusion : le constat honnête n'est pas « la queue suit une loi de puissance d'exposant $\alpha \approx 5$ », mais « la queue empirique est systématiquement plus lourde que ne le prédit la composante log-normale du mélange, et une queue de type Pareto/Singh-Maddala l'approxime mieux localement — sans que cela constitue une loi d'échelle stationnaire du système ».

6 Recommandations pratiques

- Pour un usage descriptif courant (comparaison de scénarios, résumé d'une distribution), le **mélange à 2 log-normales** reste le meilleur choix « clé en main » : il gagne l'AIC et le BIC dans la quasi-totalité des simulations stationnaires testées, pour les deux variables.
- **Ne pas interpréter ses deux composantes comme deux types économiques.** Elles correspondent à des cohortes d'âge, directement vérifiables via `creation_step` dans `entity_final_state.csv`. Si une lecture par cohorte est utile, il vaut mieux conditionner explicitement sur l'âge plutôt que de laisser le mélange statistique jouer ce rôle par proxy.
- **Ne pas extrapoler la queue du mélange** pour des usages sensibles aux événements rares (risque systémique, taille de cascade maximale) : la composante log-normale de queue sous-estime probablement les événements extrêmes. Un mélange log-normale + Pareto (déjà implémenté dans le dépôt sous `_fit_lognormal_pareto`) est plus prudent pour ce type d'usage, même s'il perd légèrement au score AIC/BIC global.
- Le GB2 (4 paramètres) ne doit **pas** être utilisé tel quel malgré son bon AIC : son optimum numérique est dégénéré sur ces données. Il a valeur de diagnostic (aucune famille lisse ne suffit), pas de recommandation.

7 Limites et pistes

- L’essentiel des 163 simulations stationnaires est à α *homogène* ($\alpha_{\min} = \alpha_{\max}$); dans ce régime, `revenu_total` est presque une fonction déterministe de `actif_total` ($\Pi = \alpha\sqrt{P}$ à α constant), donc l’accord entre les résultats « taille » et « revenu » n’est pas une confirmation indépendante. Les groupes à $\sigma_\alpha > 0$ seraient le vrai test d’indépendance, mais trop peu de simulations y sont stationnaires ($n \leq 7$) pour trancher solidement.
- Le drift positif documenté du brownien sur α (`simulation.py`, commentaire « *GROS PROBLEME!!! DRIFT POSITIF* ») explique pourquoi 80 % des simulations disponibles ne sont pas stationnaires. Le corriger permettrait d’obtenir davantage de simulations stationnaires à $\sigma_\alpha > 0$, et donc un vrai test indépendant taille/revenu.
- Piste directe pour vérifier le résultat 3 : fitter séparément les deux sous-populations obtenues en conditionnant sur l’âge (via `creation_step`) et vérifier que la bimodalité disparaît à l’intérieur de chaque cohorte.
- L’échelle de familles testées est positive uniquement. `revenu_net` (revenu moins charges d’intérêts) peut être négatif et n’a pas été traité ici; il demanderait une famille adaptée (normale asymétrique, ou décomposition explicite revenu brut moins charges).

Reproductibilité

Le code d’ajustement (`scripts/families.py`), le chargement des données (`scripts/lib.py`), l’exécution parallèle (`scripts/batch_run.py`), l’agrégation (`scripts/aggregate.py`) et le test de queue (`scripts/tail_test.py`) sont fournis avec ce rapport, ainsi que les résultats bruts par simulation (`results/*.json`, 163 fichiers). Dépôt : <https://github.com/ajossto/LIED-StageAJS>.